

1 Import thư viện và nạp dữ liệu vào notebook

```
In [1]: import pandas as pd
import numpy as np

# Đọc file csv
wine = pd.read_csv("winequality-red.csv")

# Sao chép sang dataframe khác để thao tác
df = wine.copy()

# Xem 10 dòng đầu
df.head(10)

# Kiểm tra kiểu dữ liệu và kích thước tập dữ liệu
print(df.dtypes)
print("Shape:", df.shape)
```

```
fixed acidity      float64
volatile acidity   float64
citric acid        float64
residual sugar     float64
chlorides          float64
free sulfur dioxide float64
total sulfur dioxide float64
density            float64
pH                 float64
sulphates          float64
alcohol            float64
quality            int64
dtype: object
Shape: (1599, 12)
```

2 Loại bỏ dữ liệu trùng lặp

```
In [2]: # Loại bỏ các dòng trùng lặp
df = df.drop_duplicates()

# Kiểm tra kích thước sau khi loại bỏ
print("Shape sau khi loại bỏ duplicates:", df.shape)

# Ví dụ: xóa một dòng cụ thể nếu cần
# df.drop(labels=[1], axis=0)

# Ví dụ: xóa một cột cụ thể nếu cần
# df.drop(labels=['pH'], axis=1)
```

Shape sau khi loại bỏ duplicates: (1359, 12)

3 Thay thế dữ liệu & thay đổi định dạng dữ liệu

```
In [3]: # Kiểm tra các giá trị 0 (nếu có) ở các cột quan trọng
print((df == 0).sum())

# Với một số cột như 'residual sugar' hay 'chlorides',
# nếu có giá trị 0 không hợp lý, có thể thay bằng NaN
cols_replace_zero = ['residual sugar', 'chlorides', 'sulphates', 'alcohol']
df[cols_replace_zero] = df[cols_replace_zero].replace(0, np.nan)

# Tạo thêm cột phân loại chất lượng rượu
df['quality_label'] = pd.cut(df['quality'],
                             bins=[0,5,7,10],
                             labels=['Low', 'Medium', 'High'])

# Chuyển kiểu dữ liệu quality về int (nếu cần)
df['quality'] = df['quality'].astype(int)

# Kiểm tra lại dữ liệu
df.head()
```

```
fixed acidity      0
volatile acidity   0
citric acid       118
residual sugar     0
chlorides          0
free sulfur dioxide 0
total sulfur dioxide 0
density           0
pH                0
sulphates         0
alcohol           0
quality           0
dtype: int64
```

```
Out[3]:
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
0	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51	0.56	0
1	7.8	0.88	0.00	2.6	0.098	25.0	67.0	0.9968	3.20	0.68	0
2	7.8	0.76	0.04	2.3	0.092	15.0	54.0	0.9970	3.26	0.65	0
3	11.2	0.28	0.56	1.9	0.075	17.0	60.0	0.9980	3.16	0.58	0
5	7.4	0.66	0.00	1.8	0.075	13.0	40.0	0.9978	3.51	0.56	0

4 Xử lý dữ liệu thiếu

```
In [4]: # Kiểm tra số lượng giá trị thiếu
print(df.isnull().sum())

# Điền giá trị trung vị cho các cột số bị thiếu
df_filled = df.fillna(df.median(numeric_only=True))
```

```
# Hoặc Loại bỏ các dòng thiếu
# df_clean = df.dropna(how='any')

print("Shape sau khi xử lý missing:", df_filled.shape)
```

fixed acidity	0
volatile acidity	0
citric acid	0
residual sugar	0
chlorides	0
free sulfur dioxide	0
total sulfur dioxide	0
density	0
pH	0
sulphates	0
alcohol	0
quality	0
quality_label	0

```
dtype: int64
Shape sau khi xử lý missing: (1359, 13)
```

5 Thống kê mô tả cơ bản

```
In [5]: # Thống kê nhanh
print(df_filled.describe())

# Lấy mean, median, mode cho cột alcohol
alcohol_mean = df_filled['alcohol'].mean()
alcohol_median = df_filled['alcohol'].median()
alcohol_mode = df_filled['alcohol'].mode()[0]

print("Mean alcohol:", alcohol_mean)
print("Median alcohol:", alcohol_median)
print("Mode alcohol:", alcohol_mode)

# Tính phương sai, độ lệch chuẩn, min, max
alcohol_var = np.var(df_filled['alcohol'])
alcohol_std = np.std(df_filled['alcohol'])
alcohol_min = np.min(df_filled['alcohol'])
alcohol_max = np.max(df_filled['alcohol'])

print("Variance:", alcohol_var)
print("Std dev:", alcohol_std)
print("Min:", alcohol_min)
print("Max:", alcohol_max)

# Percentile & IQR
alcohol_60 = np.percentile(df_filled['alcohol'], 60)
alcohol_iqr = np.percentile(df_filled['alcohol'], 75) - np.percentile(df_filled['alcohol'], 25)

print("60th percentile:", alcohol_60)
print("IQR:", alcohol_iqr)
```

	fixed acidity	volatile acidity	citric acid	residual sugar \
count	1359.000000	1359.000000	1359.000000	1359.000000
mean	8.310596	0.529478	0.272333	2.523400
std	1.736990	0.183031	0.195537	1.352314
min	4.600000	0.120000	0.000000	0.900000
25%	7.100000	0.390000	0.090000	1.900000
50%	7.900000	0.520000	0.260000	2.200000
75%	9.200000	0.640000	0.430000	2.600000
max	15.900000	1.580000	1.000000	15.500000

	chlorides	free sulfur dioxide	total sulfur dioxide	density \
count	1359.000000	1359.000000	1359.000000	1359.000000
mean	0.088124	15.893304	46.825975	0.996709
std	0.049377	10.447270	33.408946	0.001869
min	0.012000	1.000000	6.000000	0.990070
25%	0.070000	7.000000	22.000000	0.995600
50%	0.079000	14.000000	38.000000	0.996700
75%	0.091000	21.000000	63.000000	0.997820
max	0.611000	72.000000	289.000000	1.003690

	pH	sulphates	alcohol	quality
count	1359.000000	1359.000000	1359.000000	1359.000000
mean	3.309787	0.658705	10.432315	5.623252
std	0.155036	0.170667	1.082065	0.823578
min	2.740000	0.330000	8.400000	3.000000
25%	3.210000	0.550000	9.500000	5.000000
50%	3.310000	0.620000	10.200000	6.000000
75%	3.400000	0.730000	11.100000	6.000000
max	4.010000	2.000000	14.900000	8.000000

Mean alcohol: 10.432315428010792

Median alcohol: 10.2

Mode alcohol: 9.5

Variance: 1.170004073835233

Std dev: 1.0816672657685602

Min: 8.4

Max: 14.9

60th percentile: 10.5

IQR: 1.5999999999999996