

1 Import thư viện và nạp dữ liệu vào notebook

```
In [1]: import pandas as pd
import numpy as np

# Đặt tên cột
columns = ['Pregnancies', 'Glucose', 'BloodPressure', 'SkinThickness', 'Insulin',
           'BMI', 'DiabetesPedigreeFunction', 'Age', 'Outcome']

# Đọc file csv
df_dataset = pd.read_csv('./pima-indians-diabetes.csv', names=columns)

# Xem vài dòng đầu tiên
display(df_dataset.head())

# Kiểm tra kiểu dữ liệu và kích thước tập dữ liệu
print(df_dataset.dtypes)
print("Shape:", df_dataset.shape)
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction
0	6	148	72	35	0	33.6	0.6
1	1	85	66	29	0	26.6	0.3
2	8	183	64	0	0	23.3	0.6
3	1	89	66	23	94	28.1	0.1
4	0	137	40	35	168	43.1	2.2

```
Pregnancies      int64
Glucose           int64
BloodPressure     int64
SkinThickness     int64
Insulin           int64
BMI               float64
DiabetesPedigreeFunction float64
Age               int64
Outcome           int64
dtype: object
Shape: (768, 9)
```

2 Loại bỏ dữ liệu trùng lặp

```
In [2]: # Loại bỏ các dòng trùng lặp
df_dataset = df_dataset.drop_duplicates()

# Kiểm tra lại kích thước sau khi loại bỏ
print("Shape sau khi loại bỏ duplicates:", df_dataset.shape)
```

```
# Ví dụ: xóa một dòng cụ thể (nếu cần)
# df_dataset.drop(labels=[1], axis=0)

# Ví dụ: xóa một cột cụ thể (nếu cần)
# df_dataset.drop(labels=['SkinThickness'], axis=1)
```

Shape sau khi loại bỏ duplicates: (768, 9)

3 Thay thế dữ liệu & thay đổi định dạng dữ liệu

```
In [3]: # Thay thế giá trị 0 ở các cột có thể bị missing bằng NaN (theo thực tế y học)
cols_with_zero = ['Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI']
df_dataset[cols_with_zero] = df_dataset[cols_with_zero].replace(0, np.nan)

# Thêm cột phân loại theo độ tuổi
df_dataset['Age_Group'] = pd.cut(df_dataset['Age'],
                                bins=[0, 30, 50, 100],
                                labels=['Young', 'Middle Age', 'Senior'])

# Đổi kiểu dữ liệu của Pregnancies sang int (nếu cần)
df_dataset['Pregnancies'] = df_dataset['Pregnancies'].astype(int)

# Kiểm tra lại
df_dataset.head()
```

```
Out[3]:
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunc
0	6	148.0	72.0	35.0	NaN	33.6	
1	1	85.0	66.0	29.0	NaN	26.6	
2	8	183.0	64.0	NaN	NaN	23.3	
3	1	89.0	66.0	23.0	94.0	28.1	
4	0	137.0	40.0	35.0	168.0	43.1	

4 Xử lý dữ liệu thiếu

```
In [4]: # Kiểm tra số lượng missing values
print(df_dataset.isnull().sum())

# Điền giá trị trung vị cho các cột bị thiếu (vì là dữ liệu số)
df_dataset_filled = df_dataset.fillna(df_dataset.median(numeric_only=True))

# Hoặc nếu muốn loại bỏ các dòng có giá trị thiếu
# df_dataset_clean = df_dataset.dropna(how='any')

print("Shape sau khi xử lý missing:", df_dataset_filled.shape)
```

```

Pregnancies      0
Glucose           5
BloodPressure     35
SkinThickness     227
Insulin           374
BMI               11
DiabetesPedigreeFunction  0
Age               0
Outcome           0
Age_Group         0
dtype: int64
Shape sau khi xử lý missing: (768, 10)

```

5 Thống kê mô tả cơ bản (Tuỳ chọn — giống phần Covid)

```

In [5]: # Thống kê nhanh toàn bộ dataset
print(df_dataset_filled.describe())

# Lấy mean, median, mode của cột Glucose
glucose_mean = df_dataset_filled['Glucose'].mean()
glucose_median = df_dataset_filled['Glucose'].median()
glucose_mode = df_dataset_filled['Glucose'].mode()[0]

print("Mean Glucose:", glucose_mean)
print("Median Glucose:", glucose_median)
print("Mode Glucose:", glucose_mode)

```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin \
count	768.000000	768.000000	768.000000	768.000000	768.000000
mean	3.845052	121.656250	72.386719	29.108073	140.671875
std	3.369578	30.438286	12.096642	8.791221	86.383060
min	0.000000	44.000000	24.000000	7.000000	14.000000
25%	1.000000	99.750000	64.000000	25.000000	121.500000
50%	3.000000	117.000000	72.000000	29.000000	125.000000
75%	6.000000	140.250000	80.000000	32.000000	127.250000
max	17.000000	199.000000	122.000000	99.000000	846.000000

	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	768.000000	768.000000	768.000000
mean	32.455208	0.471876	33.240885	0.348958
std	6.875177	0.331329	11.760232	0.476951
min	18.200000	0.078000	21.000000	0.000000
25%	27.500000	0.243750	24.000000	0.000000
50%	32.300000	0.372500	29.000000	0.000000
75%	36.600000	0.626250	41.000000	1.000000
max	67.100000	2.420000	81.000000	1.000000

Mean Glucose: 121.65625
 Median Glucose: 117.0
 Mode Glucose: 99.0