

# Thống kê mô tả

## 1. Thống kê mô tả là gì? Nó khác gì với thống kê suy luận (inferential statistics)?

Thống kê mô tả liên quan đến các phương pháp tổ chức, tóm tắt và trình bày dữ liệu một cách có ý nghĩa. Các kỹ thuật thống kê này nhằm mục đích cung cấp một cái nhìn tổng quan rõ ràng và ngắn gọn về các tính năng và đặc điểm chính của tập dữ liệu. Thống kê mô tả không liên quan đến việc đưa ra các suy luận hoặc khái quát hóa về một quần thể lớn hơn; thay vào đó, mục đích chính của họ là cung cấp thông tin chuyên sâu về tập dữ liệu cụ thể đang được phân tích

### **Biện pháp của xu hướng trung ương:**

Thống kê mô tả bao gồm các thước đo về xu hướng trung tâm, chẳng hạn như giá trị trung bình, trung vị và chế độ. Các thước đo này cung cấp giá trị trung tâm hoặc giá trị đại diện xung quanh cụm điểm dữ liệu, mang lại ý nghĩa về giá trị điển hình của tập dữ liệu.

### **Các biện pháp phân tán:**

Một khía cạnh khác của thống kê mô tả liên quan đến các thước đo độ phân tán, chẳng hạn như phạm vi, phương sai và độ lệch chuẩn. Các thước đo này giúp đánh giá mức độ phân tán hoặc tính biến đổi của các điểm dữ liệu, cung cấp thông tin về mức độ sai lệch của các giá trị dữ liệu riêng lẻ so với xu hướng trung tâm.

### **Data Visualization:**

Thống kê mô tả thường được bổ sung bằng cách biểu diễn dữ liệu trực quan, bao gồm biểu đồ, biểu đồ hộp và biểu đồ phân tán. Những hình ảnh trực quan này nâng cao sự hiểu biết về phân bố, mẫu và các ngoại lệ tiềm năng của dữ liệu.

### **Thống kê suy luận là gì?**

Thống kê suy luận liên quan đến việc rút ra kết luận hoặc suy luận về dân số dựa trên mẫu dữ liệu. Nhánh thống kê này sử dụng lý thuyết xác suất và kiểm tra giả thuyết để ngoại suy các phát hiện ngoài mẫu được quan sát.

## **Ý chính:**

Dân số và mẫu:

- Dân số: Toàn bộ nhóm đang nghiên cứu.
- Mẫu: Một tập hợp con của dân số được sử dụng để thu thập dữ liệu.

Phương pháp xét nghiệm:

- Lấy mẫu ngẫu nhiên: Mỗi thành viên của dân số đều có cơ hội như nhau để được đưa vào mẫu.
- Lấy mẫu phân tầng: Dân số được chia thành các nhóm nhỏ và các mẫu được lấy từ mỗi nhóm nhỏ.
- Lấy mẫu cụm: Dân số được chia thành các cụm và toàn bộ cụm được chọn ngẫu nhiên.

Kiểm định giả thuyết:

- Giả thuyết không ( $H_0$ ): Một tuyên bố không có hiệu lực hoặc không có sự khác biệt.
- Giả thuyết thay thế ( $H_1$ ): Một tuyên bố chỉ ra một hiệu ứng hoặc sự khác biệt.
- Mức ý nghĩa ( $\alpha$ ): Xác suất bác bỏ giả thuyết không khi nó đúng (đặt ở mức 0.05).
- Giá trị P: Xác suất đạt được kết quả quan sát được, hoặc cực đoan hơn, giả sử giả thuyết không là đúng. Giá trị p thấp hơn cho thấy bằng chứng mạnh mẽ hơn chống lại giả thuyết không.

Khoảng tin cậy:

- Một phạm vi giá trị được tính toán từ dữ liệu mẫu, trong đó tham số tổng thể thực có khả năng nằm với mức độ tin cậy nhất định (ví dụ: 95%).

Phân tích hồi quy:

- Kiểm tra mối quan hệ giữa các biến để dự đoán hoặc giải thích kết quả.

Kỹ thuật suy luận thống kê:

- T-kiểm tra: Dùng để so sánh trung bình của hai nhóm.
- ANOVA (Phân tích phương sai): So sánh phương tiện của nhiều hơn hai nhóm.
- Phân tích hồi quy: Dự đoán mối quan hệ giữa các biến phụ thuộc và độc lập.

Lỗi trong suy luận:

- Lỗi loại I: Bác bỏ một cách không chính xác một giả thuyết không đúng.
- Lỗi loại II: Không bác bỏ một giả thuyết không sai.

---

## Sự khác biệt chính giữa thống kê mô tả và suy luận

Phạm vi:

- *Thống kê mô tả*: Tóm tắt và mô tả các tính năng chính của tập dữ liệu.
- *Thống kê suy luận*: Rút ra kết luận hoặc đưa ra dự đoán về dân số dựa trên mẫu.

Mục tiêu:

- *Thống kê mô tả*: Cung cấp cái nhìn sâu sắc về các đặc điểm của dữ liệu.
- *Thống kê suy luận*: Ngoại suy các phát hiện từ một mẫu để đưa ra suy luận về tổng thể.

Phân tích dữ liệu:

- *Thống kê mô tả*: Tập trung vào việc tổ chức và tóm tắt dữ liệu bằng cách sử dụng các thước đo như giá trị trung bình, trung vị và độ lệch chuẩn.
- *Thống kê suy luận*: Liên quan đến việc kiểm tra giả thuyết, khoảng tin cậy và phân tích hồi quy để đưa ra dự đoán hoặc rút ra kết luận về dân số.

Kỹ thuật ví dụ:

- *Thống kê mô tả*: Giá trị trung bình, trung vị, mode, khoảng, độ lệch chuẩn.
- *Thống kê suy luận*: Kiểm định giả thuyết, khoảng tin cậy, phân tích hồi quy, kiểm định t, ANOVA.

Mục đích:

- *Thống kê mô tả*: Cung cấp ảnh chụp nhanh và tổng quan về tập dữ liệu.
- *Thống kê suy luận*: Nhằm mục đích đưa ra những khái quát hóa hoặc dự đoán về dân số dựa trên dữ liệu mẫu.

Dân số so với mẫu:

- *Thống kê mô tả*: Tập trung vào các đặc điểm của mẫu được quan sát.
- *Thống kê suy luận*: Liên quan đến việc đưa ra các suy luận về tổng thể lớn hơn mà từ đó mẫu được rút ra.

Ứng dụng:

- *Thống kê mô tả*: Thường được sử dụng để tóm tắt và trình bày dữ liệu một cách có ý nghĩa.
- *Thống kê suy luận*: Cần thiết để đưa ra dự đoán, rút ra kết luận và đưa ra quyết định ngoài dữ liệu được quan sát.

Kịch bản ví dụ:

- *Thống kê mô tả*: Tính thu nhập trung bình của một mẫu.
- *Thống kê suy luận*: Dự đoán thu nhập trung bình của toàn bộ dân số dựa trên dữ liệu mẫu.

## Bảng so sánh

| Tính năng | Thống kê mô tả | Thống kê suy luận |
|-----------|----------------|-------------------|
|           |                |                   |

|                    |                                                                           |                                                                      |
|--------------------|---------------------------------------------------------------------------|----------------------------------------------------------------------|
| Mục đích           | Mô tả các đặc điểm của tập dữ liệu                                        | Rút ra kết luận về dân số dựa trên mẫu                               |
| Tập trung          | Bản thân dữ liệu                                                          | Dân số được đại diện bởi dữ liệu                                     |
| Thông tin cung cấp | Các biện pháp về xu hướng trung tâm, phân tán và phân phối                | Khoảng tin cậy, giá trị p, kiểm định giả thuyết                      |
| Cỡ mẫu             | Áp dụng cho mọi kích thước                                                | Thường dựa vào mẫu, nhưng có thể áp dụng cho quần thể nhỏ            |
| Chắc chắn          | Tóm tắt dữ liệu đã biết                                                   | Đưa ra dự đoán hoặc khái quát hóa với mức độ không chắc chắn cố hữu  |
| Các ví dụ          | Giá trị trung bình, trung vị, mode, khoảng, độ lệch chuẩn, phân bố tần số | Kiểm định giả thuyết, phân tích tương quan, phân tích hồi quy, ANOVA |

|         |                                           |                                                           |
|---------|-------------------------------------------|-----------------------------------------------------------|
| Đầu ra  | Biểu đồ, bảng, đồ thị                     | Các phát biểu về dân số có xác suất đúng                  |
| Hạn chế | Không thể khái quát hóa ngoài tập dữ liệu | Yêu cầu lựa chọn mẫu cẩn thận và kiểm tra thống kê hợp lệ |

## 2. Các thước đo thống kê mô tả chính (ví dụ: trung bình, trung vị, phương sai, độ lệch chuẩn) được sử dụng để làm gì? Trong trường hợp nào thì nên dùng trung vị thay vì trung bình?

### a. Tóm tắt dữ liệu một cách tổng quan và rõ ràng

Thay vì phải đối mặt với hàng loạt con số và biểu đồ phức tạp, thống kê mô tả giúp bạn tổng hợp dữ liệu một cách nhanh chóng và dễ hiểu. Giúp bạn tìm ra các xu hướng cơ bản trong dữ liệu, chẳng hạn như giá trị trung bình, trung vị, hoặc độ lệch chuẩn, từ đó cung cấp cái nhìn tổng quan về tập dữ liệu.

### b. Xác định các khuynh hướng

Thống kê mô tả giúp bạn phát hiện các xu hướng trong dữ liệu. Chẳng hạn như sự phân phối của các giá trị hoặc các khuynh hướng bất thường (outliers). Hỗ trợ bạn tìm ra các giá trị bất thường trong tập dữ liệu, từ đó giúp định hướng cách phân tích tiếp theo.

### c. Đề xuất các phương pháp phân tích khác

Sử dụng các công cụ thống kê cơ bản để xác định xu hướng tổng quát của dữ liệu. Từ đó bạn có thể đưa ra các phương pháp phân tích nâng cao hơn, chẳng

hạn như phân tích dự đoán (predictive analytics) hoặc phân tích tương quan (correlation analysis), giúp bạn có cái nhìn sâu sắc hơn về dữ liệu.

#### **d. Tạo cơ sở cho các phương pháp phân tích nâng cao**

Trực tiếp xây dựng nền tảng cho các phương pháp phân tích dự đoán (predictive analytics) hoặc phân tích tương quan (correlation analysis), giúp bạn có cái nhìn sâu sắc hơn về dữ liệu. Các phương pháp này cho phép bạn tìm ra các mối liên hệ trong dữ liệu, từ đó đưa ra các dự đoán chính xác hơn. Đồng thời, chúng cũng giúp bạn tiết kiệm thời gian và công sức.

Thống kê mô tả là bước quan trọng đầu tiên trong phân tích dữ liệu. Nó giúp bạn có cái nhìn tổng quan về dữ liệu. Ngoài ra, thống kê mô tả còn cung cấp các thông tin hữu ích để bạn có thể thực hiện các bước phân tích nâng cao hơn. Dưới đây là một số lợi ích cụ thể khi sử dụng thống kê mô tả:

- **Hỗ trợ phát hiện các xu hướng trong dữ liệu:** Thống kê mô tả cho phép bạn nhận biết các xu hướng hoặc mẫu hình trong dữ liệu, chẳng hạn như giá trị trung bình, trung vị, hoặc độ lệch chuẩn.
- **Xác định các giá trị bất thường (outliers):** Thống kê mô tả giúp bạn phát hiện các giá trị bất thường trong tập dữ liệu, từ đó hỗ trợ bạn đưa ra các quyết định phù hợp trong quá trình phân tích dữ liệu.
- **Cung cấp nền tảng cho các phương pháp phân tích nâng cao hơn:** Dựa trên các thông tin thu thập được từ thống kê mô tả, bạn có thể áp dụng các phương pháp phân tích tiên tiến hơn như phân tích dự đoán (predictive analytics) hoặc phân tích tương quan (correlation analysis) để khám phá sâu hơn về dữ liệu.

Các thước đo thống kê mô tả chính và ứng dụng

- **Trung bình (Mean):** Đại diện cho giá trị trung tâm của tập dữ liệu, được tính bằng tổng tất cả các giá trị chia cho số lượng quan sát. Dùng để đánh giá xu hướng chung.
- **Trung vị (Median):** Giá trị nằm giữa tập dữ liệu khi sắp xếp theo thứ tự, ít bị ảnh hưởng bởi giá trị ngoại lai. Dùng để đo xu hướng trung tâm khi dữ liệu có phân bố bất thường.
- **Phương sai (Variance):** Đo mức độ phân tán của dữ liệu quanh trung bình, cho biết mức độ biến thiên.

- **Độ lệch chuẩn (Standard Deviation):** Là căn bậc hai của phương sai, thể hiện mức độ phân tán của dữ liệu theo đơn vị gốc, giúp đánh giá sự ổn định hoặc biến động.

Khi nào nên dùng trung vị thay vì trung bình?

- Khi dữ liệu có **giá trị ngoại lai** (outliers) lớn (ví dụ: thu nhập của một người rất cao trong tập dữ liệu), trung bình sẽ bị lệch, trong khi trung vị vẫn phản ánh chính xác xu hướng trung tâm.
- Khi phân bố dữ liệu **bất đối xứng** (skewed distribution), như phân phối lệch phải (right-skewed) hoặc lệch trái (left-skewed), trung vị là thước đo phù hợp hơn.
- Khi mục tiêu là so sánh thứ hạng hoặc vị trí trung bình trong tập dữ liệu thay vì giá trị trung bình số học.

### 3. Độ lệch chuẩn và phạm vi (range) có ý nghĩa gì trong việc đánh giá sự phân tán của dữ liệu?

Độ lệch chuẩn và phạm vi là hai chỉ số quan trọng trong thống kê, được sử dụng để đánh giá mức độ phân tán của dữ liệu. Phạm vi (range) được xác định bằng hiệu số giữa giá trị lớn nhất và giá trị nhỏ nhất trong tập dữ liệu, phản ánh độ trải rộng tổng thể nhưng lại dễ bị chi phối bởi các giá trị ngoại lai. Trong khi đó, độ lệch chuẩn (standard deviation) đo lường mức độ dao động trung bình của các giá trị xung quanh giá trị trung bình cộng, từ đó cho thấy dữ liệu có tập trung hay phân tán. So với phạm vi, độ lệch chuẩn được xem là thước đo đáng tin cậy và được sử dụng phổ biến hơn trong phân tích thống kê.

### 4. Sự khác biệt giữa các thước đo như Q1, Q2, Q3 trong biểu đồ hộp (boxplot) là gì? dữ liệu?

Trong biểu đồ hộp (boxplot), các thước đo Q1, Q2 và Q3 chính là các tứ phân vị, thể hiện mức phân chia dữ liệu thành bốn phần bằng nhau:

- **Q1 (Quartile 1 hay phân vị thứ nhất):** là giá trị tại vị trí 25% dữ liệu nhỏ hơn hoặc bằng nó. Q1 cho biết ranh giới dưới của phần tư đầu tiên, phản ánh xu hướng của nhóm dữ liệu nhỏ nhất.

- **Q2 (Quartile 2 hay trung vị – Median):** là giá trị chia tập dữ liệu thành hai nửa bằng nhau, tức 50% giá trị nhỏ hơn hoặc bằng nó và 50% lớn hơn hoặc bằng nó. Q2 thể hiện xu hướng trung tâm.
- **Q3 (Quartile 3 hay phân vị thứ ba):** là giá trị tại vị trí 75% dữ liệu nhỏ hơn hoặc bằng nó. Q3 cho biết ranh giới trên của phần tư thứ ba, phản ánh xu hướng của nhóm dữ liệu lớn hơn.

**Sự khác biệt:** Q1 đại diện cho xu hướng của dữ liệu ở nhóm thấp, Q2 phản ánh mức trung tâm, còn Q3 thể hiện xu hướng của dữ liệu ở nhóm cao. Khoảng cách giữa Q1 và Q3 (gọi là khoảng tứ phân vị – IQR) cho biết độ phân tán của phần lớn dữ liệu, ít bị ảnh hưởng bởi ngoại lai hơn so với phạm vi.

## 5. Làm thế nào để xử lý giá trị thiếu (missing values) trước khi tính toán các chỉ số thống kê mô tả?

### Xử Lý Giá Trị Thiếu Bằng Phương Pháp Xóa Dữ Liệu

Phương pháp xóa dữ liệu là một trong những cách tiếp cận đơn giản nhất để xử lý giá trị thiếu. Nó bao gồm việc loại bỏ các hàng (bản ghi) hoặc cột (thuộc tính) chứa các giá trị bị thiếu. Tuy nhiên, cần lưu ý rằng việc xóa dữ liệu có thể dẫn đến mất mát thông tin quan trọng và ảnh hưởng đến hiệu suất của mô hình học máy, đặc biệt khi số lượng giá trị thiếu là đáng kể.

#### 1. Xóa theo hàng (Row-wise Deletion):

- Khi một hàng chứa một hoặc nhiều giá trị thiếu, hàng đó sẽ bị loại bỏ khỏi tập dữ liệu. Phương pháp này phù hợp khi số lượng giá trị thiếu trong mỗi hàng là nhỏ và số lượng hàng bị ảnh hưởng không đáng kể so với tổng số hàng trong tập dữ liệu. Điều này giúp đảm bảo rằng việc xóa các hàng này không làm mất đi quá nhiều thông tin quan trọng.

## 2. Xóa theo cột (Column-wise Deletion):

- Nếu một cột chứa một lượng lớn giá trị thiếu (ví dụ: trên 80%), cột đó có thể bị loại bỏ. Phương pháp này được áp dụng khi cột đó không còn mang nhiều ý nghĩa hoặc không đóng góp đáng kể vào quá trình xây dựng mô hình. Tuy nhiên, cần cân nhắc kỹ lưỡng trước khi xóa một cột, vì nó có thể chứa thông tin quan trọng mà các thuộc tính khác không thể thay thế.

Ưu điểm của phương pháp xóa dữ liệu:

- Dễ thực hiện và triển khai.
- Không làm thay đổi phân phối của dữ liệu còn lại.

Nhược điểm của phương pháp xóa dữ liệu:

- Có thể dẫn đến mất mát thông tin quan trọng.
- Làm giảm kích thước tập dữ liệu, có thể ảnh hưởng đến hiệu suất của mô hình.
- Có thể tạo ra sai lệch trong dữ liệu nếu giá trị thiếu không phân bố ngẫu nhiên.

Việc lựa chọn phương pháp xóa theo hàng hay theo cột phụ thuộc vào số lượng và phân bố của giá trị thiếu, cũng như tầm quan trọng của các thuộc tính trong tập dữ liệu. Cần cân nhắc kỹ lưỡng các ưu và nhược điểm của từng phương pháp để đưa ra quyết định phù hợp nhất cho từng trường hợp cụ thể.

Khi nào nên sử dụng phương pháp xóa dữ liệu?

- Khi số lượng giá trị thiếu là rất nhỏ so với tổng kích thước tập dữ liệu.
- Khi các hàng hoặc cột chứa giá trị thiếu không mang nhiều ý nghĩa hoặc không ảnh hưởng đáng kể đến kết quả phân tích.
- Khi không có đủ thông tin hoặc nguồn lực để thực hiện các phương pháp xử lý giá trị thiếu phức tạp hơn.

## Thay Thế Giá Trị Thiếu: Các Phương Pháp Phổ Biến

Phương pháp thay thế giá trị thiếu là một kỹ thuật phổ biến để điền vào các ô dữ liệu bị thiếu bằng một giá trị ước tính. Cách tiếp cận này giúp bảo toàn kích thước tập dữ liệu và tránh mất mát thông tin, nhưng cần lựa chọn phương pháp thay thế phù hợp để không làm sai lệch phân phối dữ liệu gốc.

### 1. Thay thế bằng giá trị trung bình (Mean Imputation):

- Giá trị thiếu trong một cột số được thay thế bằng giá trị trung bình của các giá trị còn lại trong cột đó. Phương pháp này đơn giản và dễ thực hiện, nhưng có thể bị ảnh hưởng bởi các giá trị ngoại lệ (outliers) và làm giảm phương sai của dữ liệu.

### 2. Thay thế bằng giá trị trung vị (Median Imputation):

- Giá trị thiếu được thay thế bằng giá trị trung vị của các giá trị còn lại trong cột đó. Phương pháp này ít bị ảnh hưởng bởi outliers hơn so với giá trị trung bình và thường được sử dụng khi dữ liệu có phân phối lệch.

### 3. Thay thế bằng Mode (Mode Imputation):

- Đối với các cột dữ liệu phân loại, giá trị thiếu được thay thế bằng giá trị xuất hiện nhiều nhất (mode) trong cột đó. Phương pháp này đảm bảo rằng các giá trị thay thế là hợp lệ và phù hợp với loại dữ liệu.

### 4. Thay thế bằng hằng số (Constant Value Imputation):

- Giá trị thiếu được thay thế bằng một giá trị hằng số do người dùng chỉ định. Giá trị này có thể dựa trên kiến thức chuyên môn về dữ liệu hoặc được chọn để biểu thị một ý nghĩa cụ thể (ví dụ: thay thế giá trị thiếu bằng 0 hoặc -1).

Ưu điểm của phương pháp thay thế giá trị thiếu:

- Dễ thực hiện và triển khai.
- Không làm giảm kích thước tập dữ liệu.

Nhược điểm của phương pháp thay thế giá trị thiếu:

- Có thể làm sai lệch phân phối của dữ liệu.
- Có thể làm giảm phương sai của dữ liệu.
- Không tính đến mối tương quan giữa các thuộc tính.

Lưu ý khi sử dụng phương pháp thay thế giá trị thiếu:

- Nên sử dụng các phương pháp thay thế khác nhau cho các loại dữ liệu khác nhau (ví dụ: giá trị trung bình cho dữ liệu số, mode cho dữ liệu phân loại).
- Cần xem xét tác động của việc thay thế giá trị thiếu đến hiệu suất của mô hình học máy.
- Có thể sử dụng các phương pháp thay thế phức tạp hơn, chẳng hạn như thay thế bằng giá trị dự đoán từ mô hình học máy.

## **Dự Đoán Giá Trị Thiếu: Sử Dụng Mô Hình Học Máy**

Một phương pháp tiên tiến hơn để xử lý giá trị thiếu là sử dụng các mô hình học máy để dự đoán các giá trị bị thiếu. Thay vì đơn giản thay thế bằng một giá trị trung bình hoặc trung vị, phương pháp này tận dụng mối quan hệ giữa các thuộc tính trong tập dữ liệu để ước tính các giá trị bị thiếu một cách chính xác hơn.

### **1. K-Nearest Neighbors (KNN) Imputation:**

- KNN là một thuật toán học máy không tham số, có thể được sử dụng để dự đoán giá trị thiếu dựa trên các hàng tương tự nhất trong tập dữ liệu. Thuật toán này tìm kiếm k hàng gần nhất với hàng chứa giá trị thiếu (dựa trên khoảng cách giữa các thuộc tính khác) và sử dụng giá trị trung bình hoặc mode của các giá trị trong k hàng này để thay thế giá trị thiếu.

### **2. Linear Regression Imputation:**

- Linear Regression là một thuật toán học máy có tham số, có thể được sử dụng để xây dựng mô hình dự đoán giá trị thiếu dựa trên các thuộc tính khác trong tập dữ liệu. Thuật toán này tìm kiếm một mối quan hệ tuyến tính giữa thuộc tính chứa giá trị thiếu và các thuộc tính khác, và sử dụng mô hình này để dự đoán giá trị thiếu.

Ưu điểm của phương pháp dự đoán giá trị thiếu:

- Có thể dự đoán giá trị thiếu một cách chính xác hơn so với các phương pháp thay thế đơn giản.
- Tính đến mối tương quan giữa các thuộc tính.

Nhược điểm của phương pháp dự đoán giá trị thiếu:

- Phức tạp hơn so với các phương pháp thay thế đơn giản.
- Có thể tốn nhiều thời gian và tài nguyên tính toán.
- Hiệu suất phụ thuộc vào chất lượng của mô hình học máy.

Khi nào nên sử dụng phương pháp dự đoán giá trị thiếu?

- Khi có mối tương quan mạnh mẽ giữa các thuộc tính.
- Khi muốn dự đoán giá trị thiếu một cách chính xác nhất có thể.
- Khi có đủ thời gian và nguồn lực để xây dựng và đánh giá mô hình học máy.


Bảng so sánh các phương pháp xử lý giá trị thiếu:




| Phương pháp | Ưu điểm | Nhược điểm | Khi nào nên sử dụng |
|-------------|---------|------------|---------------------|
|-------------|---------|------------|---------------------|

|                  |                                                     |                                                                      |                                                                                    |
|------------------|-----------------------------------------------------|----------------------------------------------------------------------|------------------------------------------------------------------------------------|
| Xóa dữ liệu      | Dễ thực hiện, không làm thay đổi phân phối dữ liệu  | Mất thông tin, giảm kích thước tập dữ liệu, có thể tạo ra sai lệch   | Số lượng giá trị thiếu nhỏ, không có đủ thông tin để thay thế                      |
| Thay thế giá trị | Dễ thực hiện, không làm giảm kích thước tập dữ liệu | Có thể làm sai lệch phân phối dữ liệu, không tính đến mối tương quan | Số lượng giá trị thiếu vừa phải, có thể ước tính giá trị thay thế hợp lý           |
| Dự đoán giá trị  | Dự đoán chính xác hơn, tính đến mối tương quan      | Phức tạp, tốn thời gian, hiệu suất phụ thuộc vào mô hình             | Có mối tương quan mạnh mẽ giữa các thuộc tính, muốn dự đoán giá trị chính xác nhất |

## 6. Làm thế nào để xác định phân bố của một tập dữ liệu? Các loại phân bố phổ biến là gì (ví dụ: phân bố chuẩn, lệch trái, lệch phải)?

| Phương thức              | Diễn giải                                                                                                                                                                      |
|--------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Vẽ biểu đồ               | Cách trực quan nhất để nhận biết phân bố dữ liệu. Ví dụ: <i>Histogram</i> thể hiện hình dạng phân bố; <i>Boxplot</i> cho thấy độ lệch, mức tập trung và các giá trị ngoại lai. |
| Tính các chỉ số thống kê | Giúp hiểu sâu hơn về đặc điểm phân bố. Ví dụ: <i>Mean</i> (trung bình), <i>Median</i> (trung vị), <i>Mode</i> , <i>độ lệch chuẩn</i> , <i>Độ lệch (skewness)</i> .             |

| Loại phân bố      | Đặc điểm                                                                                                               |
|-------------------|------------------------------------------------------------------------------------------------------------------------|
| Phân bố chuẩn     | Hình chuông, đối xứng quanh trung bình. Mean = Median = Mode.                                                          |
| Phân bố lệch trái |  <p>Mean &gt; Median &gt; Mode.</p> |
| Phân bố lệch phải | Mean < Median < Mode. Đuôi kéo dài về bên trái.                                                                        |
| Phân bố đều       | Mọi giá trị trong khoảng đều có xác suất như nhau.                                                                     |

|                        |                                                                                                                            |
|------------------------|----------------------------------------------------------------------------------------------------------------------------|
|                        |                                           |
| <b>Phân bố mũ</b>      | <p>Xác suất giảm dần theo thời gian.</p>  |
| <b>Phân bố đa đỉnh</b> | <p>Có nhiều đỉnh</p>                     |

## 7. Bạn có thể giải thích cách đọc và diễn giải một biểu đồ histogram hoặc boxplot từ dữ liệu thực tế không?

| <b>Biểu đồ</b>   | <b>Cách đọc</b>                                                                                                                                                                                                                              |
|------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Histogram</b> | <p>Trục hoành: Đại diện cho các khoảng giá trị (còn gọi là “bins” hoặc “lớp”). Mỗi cột biểu thị một khoảng giá trị cụ thể của dữ liệu</p> <p>Trục tung: Đại diện cho tần suất (frequency) – số lượng dữ liệu rơi vào mỗi khoảng giá trị.</p> |
| <b>Boxplot</b>   | <ul style="list-style-type: none"> <li>- Đường giữa hộp: Median (trung vị) – giá trị giữa dữ liệu.</li> <li>- Cạnh dưới hộp: Q1 (25%) – 25% dữ liệu nhỏ hơn giá trị này.</li> <li>- Cạnh trên hộp: Q3 (75%) – 75% dữ liệu nhỏ hơn</li> </ul> |

|  |                                                                                                                                                                                                                                                                                                                                                                                         |
|--|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|  | <p>giá trị này.</p> <ul style="list-style-type: none"> <li>- Hộp (<math>Q1 \rightarrow Q3</math>): IQR (Interquartile Range) – nơi tập trung 50% dữ liệu giữa.</li> <li>- “Râu” (whiskers): phạm vi dữ liệu bình thường ngoài hộp (thường <math>Q1 - 1.5 \times IQR</math> đến <math>Q3 + 1.5 \times IQR</math>).</li> <li>- Điểm lẻ ngoài râu: Outlier – giá trị ngoại lai.</li> </ul> |
|--|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

## 8. Khi gặp một tập dữ liệu có giá trị ngoại lai (outliers), bạn sẽ xử lý chúng như thế nào trước khi thực hiện thống kê mô tả?

Kiểm tra: là lỗi nhập dữ liệu hay giá trị hợp lý nhưng hiếm?

- Lỗi nhập (ví dụ: gõ nhầm 10000 thay vì 1000) → sửa hoặc bỏ.
- Giá trị hiếm nhưng hợp lý (ví dụ: thu nhập cực cao) → giữ hoặc tách riêng.

Báo cáo riêng nhóm outlier.