

+ **Phân tích đơn biến (univariate analysis) là gì? Nó khác gì với phân tích hai biến (bivariate analysis) trong khám phá dữ liệu?**

Trả lời:

Phân tích đơn biến là quá trình mô tả và tóm tắt đặc điểm của **một biến duy nhất** trong tập dữ liệu. Mục tiêu chính là hiểu rõ phân phối, xu hướng trung tâm, độ phân tán và hình dạng của biến đó mà không xét đến mối quan hệ với các biến khác.

Ngược lại, phân tích hai biến là quá trình khám phá **mối quan hệ giữa hai biến**. Nó giúp xác định xem hai biến có liên quan với nhau không, và nếu có thì mức độ và kiểu quan hệ là gì (tuyến tính, phi tuyến, tương quan, nhân quả...).

So sánh:

Tiêu chí	Phân tích đơn biến	Phân tích hai biến
Số lượng biến	Một	Hai
Mục tiêu chính	Mô tả đặc điểm của một biến	Khám phá mối quan hệ giữa hai biến
Kỹ thuật phổ biến	Thống kê mô tả, biểu đồ histogram	Tương quan, hồi quy, scatter plot
Ví dụ minh họa	Phân tích điểm trung bình môn Toán	Phân tích mối liên hệ giữa giờ học và điểm thi

+ Các thước đo thống kê nào thường được sử dụng trong phân tích đơn biến (ví dụ: trung bình, trung vị, mode, độ lệch chuẩn)?

Trả lời:

Trong phân tích đơn biến, các thước đo thống kê được sử dụng để mô tả đặc điểm của biến bao gồm:

_ Thước đo xu hướng trung tâm:

- **Trung bình (Mean):** Giá trị trung tâm của dữ liệu, tính bằng tổng các giá trị chia cho số lượng quan sát.
- **Trung vị (Median):** Giá trị nằm giữa tập dữ liệu khi sắp xếp theo thứ tự; ít bị ảnh hưởng bởi giá trị ngoại lai.
- **Mode (Giá trị thường xuyên nhất):** Giá trị xuất hiện nhiều nhất trong tập dữ liệu.

_ Thước đo độ phân tán:

- **Độ lệch chuẩn (Standard Deviation):** Đo mức độ phân tán của dữ liệu quanh trung bình.
- **Phương sai (Variance):** Trung bình bình phương độ lệch của các giá trị so với trung bình.
- **Khoảng (Range):** Hiệu số giữa giá trị lớn nhất và nhỏ nhất.
- **IQR (Interquartile Range):** Khoảng giữa phần tư thứ nhất (Q1) và phần tư thứ ba (Q3), dùng để phát hiện ngoại lai.

_ Thước đo hình dạng phân phối:

- **Skewness (Độ lệch):** Đo độ bất đối xứng của phân phối.
- **Kurtosis (Độ nhọn):** Đo độ dốc và độ tập trung của phân phối.

_ Biểu đồ trực quan:

- **Histogram:** Hiện thị tần suất phân phối.
- **Boxplot:** Phát hiện ngoại lai và mô tả phân phối.
- **Bar chart, Pie chart:** Dùng cho biến phân loại.

+ Trong phân tích hai biến, làm thế nào để xác định mối quan hệ giữa hai biến (ví dụ: tương quan, nhân quả)?

Trả lời:

Để xác định mối quan hệ giữa hai biến trong phân tích hai biến, ta sử dụng các kỹ thuật sau:

_ Tương quan (Correlation):

- **Hệ số tương quan Pearson:** Đo mức độ liên hệ tuyến tính giữa hai biến định lượng. Giá trị nằm trong khoảng từ -1 đến 1.
 - Gần +1: Quan hệ thuận mạnh.
 - Gần -1: Quan hệ nghịch mạnh.
 - Gần 0: Không có quan hệ tuyến tính.
- **Hệ số tương quan Spearman:** Dùng cho dữ liệu thứ bậc hoặc không tuyến tính.

_ Biểu đồ trực quan:

- **Scatter plot:** Giúp quan sát xu hướng giữa hai biến định lượng.
- **Bảng chéo (Cross-tabulation):** Dùng cho hai biến phân loại để kiểm tra phân phối đồng thời.

_ Phân tích hồi quy (Regression Analysis):

- **Hồi quy tuyến tính đơn:** Ước lượng ảnh hưởng của biến độc lập lên biến phụ thuộc.
- **Hồi quy đa biến:** Kiểm soát các biến nhiễu để xác định ảnh hưởng thực sự.

_ Kiểm định giả thuyết:

- **Kiểm định t-test:** So sánh trung bình giữa hai nhóm.
- **Kiểm định chi-square:** Kiểm tra sự khác biệt giữa phân phối của hai biến phân loại.

Lưu ý về nhân quả:

- Tương quan không đồng nghĩa với nhân quả.
- Để xác định **quan hệ nhân quả**, cần:
 - Thiết kế thí nghiệm có kiểm soát.
 - Loại bỏ biến nhiễu.
 - Dùng các mô hình thống kê nâng cao (ví dụ: hồi quy đa biến, phân tích chuỗi thời gian, mô hình nhân quả).

+ Sự khác biệt giữa tương quan (correlation) và hiệp biến (covariance) trong phân tích hai biến là gì?

Trả lời:

Hiệp biến (Covariance) và **tương quan (Correlation)** đều là thước đo thống kê dùng để đánh giá **mối quan hệ giữa hai biến định lượng**, nhưng chúng khác nhau về cách biểu diễn và khả năng so sánh:

Tiêu chí	Hiệp biến (Covariance)	Tương quan (Correlation)
Định nghĩa	Đo mức độ hai biến thay đổi cùng nhau	Chuẩn hóa độ thay đổi để nằm trong khoảng [-1, 1]
Giá trị	Không giới hạn, phụ thuộc đơn vị đo	Luôn nằm trong [-1, 1]
Ý nghĩa	> 0: biến tăng cùng nhau < 0: biến tăng nghịch nhau = 0: không liên hệ	Gần +1: quan hệ thuận mạnh Gần -1: quan hệ nghịch mạnh Gần 0: không có quan hệ tuyến tính
Đơn vị đo	Phụ thuộc vào đơn vị của hai biến	Không có đơn vị, dễ so sánh
Ứng dụng	Dùng trong tính toán ma trận hiệp biến	Dùng để đánh giá mức độ liên hệ tuyến tính

Tóm lại: Tương quan là phiên bản chuẩn hóa của hiệp biến, giúp dễ dàng so sánh mức độ liên hệ giữa các cặp biến khác nhau.

+ Khi nào nên sử dụng biểu đồ trực quan hóa trong phân tích đơn biến so với phân tích hai biến?

Trả lời:

Biểu đồ trực quan hóa là công cụ quan trọng giúp **hiểu sâu và truyền đạt thông tin** trong phân tích dữ liệu. Việc lựa chọn biểu đồ phù hợp phụ thuộc vào số lượng biến và loại dữ liệu.

_ Trong phân tích đơn biến:

- **Mục tiêu:** Mô tả phân phối, xu hướng trung tâm, độ phân tán của một biến.
- **Biểu đồ thường dùng:**
 - *Histogram*: Hiển thị tần suất phân phối của biến số.
 - *Boxplot*: Phát hiện giá trị ngoại lai và mô tả phân phối.
 - *Bar chart, Pie chart*: Dùng cho biến phân loại.

_ Trong phân tích hai biến:

- **Mục tiêu:** Khám phá mối quan hệ giữa hai biến.
- **Biểu đồ thường dùng:**
 - *Scatter plot*: Hiển thị xu hướng giữa hai biến định lượng.
 - *Heatmap*: Hiển thị ma trận tương quan giữa nhiều cặp biến.
 - *Grouped bar chart*: So sánh giữa các nhóm phân loại.
 - *Line chart*: Dùng khi một biến là chuỗi thời gian.

Tóm lại: Biểu đồ đơn biến giúp hiểu rõ đặc điểm của từng biến, còn biểu đồ hai biến giúp khám phá mối quan hệ giữa các biến.

+ Đoạn code mẫu để tạo biểu đồ scatter plot hoặc heatmap để phân tích mối quan hệ giữa hai biến?

Trả lời:


Dưới đây là ví dụ bằng Python sử dụng thư viện **Matplotlib**, **Seaborn** và **Pandas** – các công cụ phổ biến trong phân tích dữ liệu:

+ Scatter Plot – Phân tích mối quan hệ giữa hai biến định lượng

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Tạo dữ liệu mẫu
df = pd.DataFrame({
    'Hours_Studied': [1, 2, 3, 4, 5, 6, 7],
    'Exam_Score': [50, 55, 65, 70, 75, 80, 85]
})

# Vẽ scatter plot
sns.scatterplot(data=df, x='Hours_Studied', y='Exam_Score')
plt.title('Mối quan hệ giữa giờ học và điểm thi')
plt.xlabel('Giờ học')
plt.ylabel('Điểm thi')
plt.show()
```




+ Heatmap – Phân tích ma trận tương quan giữa nhiều biến

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Tạo DataFrame mẫu
df = pd.DataFrame({
    'Toán': [8, 9, 7, 6, 10],
    'Văn': [7, 8, 6, 5, 9],
    'Anh': [9, 8, 7, 6, 10]
})

# Tính ma trận tương quan
corr_matrix = df.corr()

# Vẽ heatmap
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm')
plt.title('Heatmap ma trận tương quan')
plt.show()
```



Ghi chú:

- **annot=True:** Hiển thị giá trị tương quan trên heatmap.
- **cmap='coolwarm':** Chọn bảng màu trực quan.

+ Làm thế nào để trực quan hóa mối quan hệ giữa một biến số và một biến phân loại bằng biểu đồ boxplot hoặc violin plot trong Python?

Trả lời:

Trong phân tích dữ liệu, khi muốn khám phá mối quan hệ giữa **một biến định lượng (số)** và **một biến phân loại (categorical)**, ta thường sử dụng các biểu đồ như **boxplot** hoặc **violin plot** để trực quan hóa sự phân phối của biến số theo từng nhóm phân loại.

+ **Boxplot (Biểu đồ hộp):**

Boxplot giúp hiển thị:

- Trung vị (median)
- Tứ phân vị (quartiles)
- Giá trị ngoại lai (outliers)
- Độ phân tán của dữ liệu trong từng nhóm


Ứng dụng: So sánh phân phối điểm số giữa các lớp học, thu nhập giữa các ngành nghề, v.v.

Ví dụ code:

```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd

# Tạo dữ liệu mẫu
df = pd.DataFrame({
    'Score': [75, 80, 85, 90, 60, 65, 70, 95, 88, 78],
    'Class': ['A', 'A', 'A', 'A', 'B', 'B', 'B', 'B', 'C', 'C']
})

# Vẽ boxplot
sns.boxplot(x='Class', y='Score', data=df)
plt.title('Phân phối điểm theo lớp học')
plt.xlabel('Lớp học')
plt.ylabel('Điểm số')
plt.show()
```

+ Violin Plot (Biểu đồ hình đàn violin):

Violin plot kết hợp giữa boxplot và biểu đồ mật độ (density plot), giúp hiển thị:

- Phân phối xác suất của dữ liệu trong từng nhóm
- Độ dày của “violin” thể hiện mật độ dữ liệu

Ứng dụng: Phân tích sâu hơn về hình dạng phân phối trong từng nhóm.


Ví dụ code:

```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd

# Tạo dữ liệu mẫu
df = pd.DataFrame({
    'Score': [75, 80, 85, 90, 60, 65, 70, 95, 88, 78],
    'Class': ['A', 'A', 'A', 'A', 'B', 'B', 'B', 'B', 'C', 'C']
})

# Vẽ violin plot
sns.violinplot(x='Class', y='Score', data=df, inner='box')
plt.title('Phân phối điểm theo lớp học (Violin Plot)')
plt.xlabel('Lớp học')
```

```
plt.ylabel('Điểm số')
plt.show()
```



Tham số `inner='box'` giúp hiển thị boxplot bên trong violin để dễ so sánh.

+ **Khi nào nên dùng boxplot vs violin plot?**

Tiêu chí	Boxplot	Violin Plot
Đơn giản, dễ đọc	Có	Không
Hiển thị mật độ phân phối	Không	Có
Phát hiện ngoại lai	Có	Có
Phân tích sâu hình dạng phân phối	Không	Có

Tóm lại:

- Dùng **boxplot** khi cần so sánh nhanh phân phối giữa các nhóm.
- Dùng **violin plot** khi muốn hiểu rõ hơn về hình dạng phân phối và mật độ dữ liệu trong từng nhóm phân loại.